

DEL CITÓMETRO A LA CONSOLA

Fundamentos de R para el manejo de datos de citometría

Jairo Ricardo Villanueva-Toledo

2026-10-08

Tabla de contenidos

Portada	4
Licencia	5
CÓDIGO Y CONTENIDO PROPIO	5
Conjuntos de datos (<i>datasets</i>) de terceros	5
Prefacio	6
Introducción	7
El cambio de paradigma: Del software cerrado al código abierto	7
El entorno de trabajo: Positron	7
Estructura y alcance de este volumen	7
Acerca del Autor	9
I I. EL ENTORNO	11
1 R & LA IDE	12
1.1 ¿Por qué usar R en lugar de software manual?	12
2 POSITRON	14
2.1 Arquitectura moderna en ciencia de datos	14
2.2 Anatomía del entorno de trabajo en Positron	15
3 ACTIVIDADES DE APRENDIZAJE	17
4 PAQUETES	18
4.1 Paquetes de R	18
4.2 Paquetes en citometría de flujo	18
5 ACTIVIDADES DE APRENDIZAJE	20
6 REPOSITORIOS	21
6.1 Repositorio de paquetes de R	21
6.1.1 CRAN	21
6.1.2 Bioconductor	21

7	ACTIVIDADES DE APRENDIZAJE	23
II	II. FORMATO DE TABLAS	24
8	ACTIVIDADES DE APRENDIZAJE	25
10	CAPÍTULO 5	27
	Síntesis	28
	Referencias	29

Portada

Licencia

CÓDIGO Y CONTENIDO PROPIO

El código fuente de los ejemplos y análisis presentados en este libro se distribuye bajo la licencia MIT (libre para su uso y modificación en tus propios análisis).

El contenido textual, explicaciones e imágenes de este libro web están sujetos a la licencia **Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional (CC BY-NC-ND 4.0)**.

La versión oficial consolidada, revisada y optimizada para formatos impresos y lectores electrónicos (eBook) estará disponible próximamente a través de los principales canales de distribución editorial.

i NOTA DEL AUTOR

Nos reservamos el derecho de publicar versiones futuras con contenido adicional, correcciones y mejoras en la arquitectura del código. Para consultas sobre derechos de uso comercial, reproducción o distribución masiva, por favor contacta al autor a través de su perfil académico o redes sociales profesionales.

Conjuntos de datos (*datasets*) de terceros

Para el desarrollo de los ejemplos y casos prácticos de análisis presentados en esta obra, se ha utilizado el dataset original “**AutoSpectral: Full Workflow Example**” (V1), creado por **Oliver Burton, James Dooley y Adrian Liston (2025)** y alojado en *Mendeley Data* (doi: [10.17632/ch5dnspd79.1](https://doi.org/10.17632/ch5dnspd79.1)).

Este conjunto de datos está disponible bajo la licencia **Creative Commons Attribution 4.0 International (CC BY 4.0)**. Los datos originales fueron procesados y modificados por el autor de este libro con fines estrictamente didácticos (incluyendo tareas de limpieza, filtrado y reestructuración para adaptar el flujo de trabajo a los ejemplos del texto). Puede consultar los términos completos de la licencia de este dataset en: <https://creativecommons.org/licenses/by/4.0/>.

Prefacio

Durante décadas, la citometría de flujo se ha consolidado como una de las herramientas más determinantes de la investigación biomédica, permitiendo caracterizar la heterogeneidad celular con resolución de célula única. Sin embargo, la rutina diaria frente al citómetro ha estado tradicionalmente ligada a un flujo de trabajo manual: adquirir las muestras, realizar compensaciones visuales, delimitar poblaciones mediante *gates* en gráficos bidimensionales (*point-and-click*) y copiar manualmente tablas de resultados a hojas de cálculo.

Este enfoque, aunque familiar y accesible en los inicios de cualquier investigador, enfrenta barreras evidentes en el laboratorio contemporáneo. Conforme los experimentos aumentan en número de marcadores, muestras y réplicas, el análisis tradicional tropieza con tres obstáculos fundamentales:

- **Subjetividad metodológica:** El trazado manual de compuertas introduce variabilidad atribuible al operador, lo que dificulta la reproducibilidad exacta de los resultados a lo largo del tiempo o entre distintos miembros de un equipo.
- **Falta de trazabilidad:** Las interfaces comerciales no siempre generan un registro auditable e inmutable de las operaciones realizadas, complicando la reconstrucción minuciosa del tratamiento de los datos.
- **Ineficiencia en el escalamiento:** Repetir secuencias idénticas de clics para decenas o cientos de archivos consume tiempo valioso de mesada y multiplica las probabilidades de cometer errores de transcripción.

Ante este panorama, la programación estadística mediante R y su repositorio especializado Bioconductor se ha posicionado como el estándar metodológico para procesar y reportar datos citométricos. No obstante, para quien proviene de la formación experimental, la transición a la programación suele percibirse como un abismo lleno de jerga computacional innecesaria.

Del citómetro a la consola: Fundamentos de R para el manejo de datos de citometría nace para derribar esa barrera. Este texto no pretende formar desarrolladores de software ni teóricos de la bioinformática; su único propósito es servir de puente entre el trabajo en la mesa de trabajo y la línea de comandos, dotando al investigador de autonomía analítica, orden y reproducibilidad desde su primera sesión de trabajo.

Introducción

El cambio de paradigma: Del software cerrado al código abierto

Aprender R en citometría no implica abandonar el criterio biológico; al contrario, significa dotarlo de rigor metodológico. La adopción de código convierte cada análisis en una bitácora científica explícita, auditable y automatizable, donde cada transformación y cálculo queda registrado de principio a fin.

El ecosistema de R permite conectar directamente los archivos crudos de adquisición con tablas procesadas y figuras listas para publicación, garantizando que cualquier experimento pueda reanalizarse exactamente bajo las mismas condiciones.

El entorno de trabajo: Positron

La adopción de R estuvo históricamente centrada en RStudio. No obstante, las necesidades actuales de la ciencia de datos han impulsado entornos más ágiles y modernos. Este libro adopta Positron como el entorno de desarrollo integrado (IDE) de referencia.

Diseñado por Posit sobre la arquitectura Code-OSS, Positron combina la potencia de un editor ligero con herramientas esenciales para el análisis biológico: consolas interactivas, visores directos de gráficos y un panel de inspección de variables optimizado. Para quien escribe código por primera vez, Positron reduce sustancialmente la curva de entrada, permitiendo explorar estructuras tabulares y matrices celulares de forma visual e intuitiva.

Estructura y alcance de este volumen

Este volumen introductorio se enfoca en los pilares mecánicos y conceptuales necesarios para importar, examinar y transformar datos citométricos sin recurrir a paquetes herméticos de caja negra. El eje central de la obra radica en desmitificar el archivo `.fcs` y dominar la estructura universal de datos en R: el `data.frame` y sus variantes modernas.

El contenido se articula en cuatro bloques progresivos:

- **Entorno y primeros pasos en Positron:** Instalación del software, configuración del intérprete de R, navegación por la consola y uso efectivo del panel Variables/Environment para inspeccionar lo que cargamos en memoria.
- **De la matriz FCS al mundo tabular (data.frame y variantes):** Comprensión de cómo paqueterías como flowCore leen la estructura de un archivo .fcs (metadatos, palabras clave e intensidades) y cómo desmitificar el objeto extrayendo la matriz de eventos celulares para transformarla en estructuras familiares: el data.frame base y sus variantes modernas (tibble y data.table).
- **Manipulación e inspección de datos celulares:** Uso de sintaxis básica y herramientas del ecosistema tidyverse para filtrar filas (eventos celulares), seleccionar columnas (marcadores/fluorocromos), renombrar canales y generar estadísticas descriptivas (medianas de fluorescencia, porcentajes y conteos).
- **Visualización gráfica inicial:** Creación de gráficos reproducibles de calidad editorial (histogramas univariados, diagramas de dispersión y densidades) mediante ggplot2, controlando escalas, títulos y estéticas para reportes y presentaciones.

Al concluir este volumen, el lector habrá sustituido la dependencia de herramientas cerradas por un flujo de trabajo transparente y reproducible, estableciendo las bases requeridas para abordar análisis avanzados en volúmenes posteriores.

Acerca del Autor



El autor es Médico Cirujano por la Universidad Autónoma de Yucatán ([UADY](#)). Posteriormente, realizó estudios de posgrado en el Centro de Investigación y de Estudios Avanzados del Instituto Politécnico Nacional ([CINVESTAV-IPN](#)), sede Zacatenco, en la Ciudad de México, donde obtuvo los grados de Maestría y Doctorado en Ciencias con especialidad en Genética y Biología Molecular.

Durante su formación de posgrado incursionó de manera paralela en bioinformática y citometría de flujo, áreas que marcarían de forma decisiva su trayectoria profesional. En bioinformática trabajó en análisis de secuencias génicas utilizando entornos UNIX y el lenguaje Perl,

incluyendo búsquedas con BLAST y diseño de *primers*. De manera simultánea, desarrolló experiencia en citometría de flujo aplicada al análisis del ciclo celular, integrando herramientas computacionales con aproximaciones experimentales para el estudio de procesos biológicos complejos. Actualmente complementa esta línea de trabajo mediante el uso de los lenguajes de programación R y Python para el análisis, procesamiento y visualización de datos biológicos.

Tras concluir el doctorado, se desempeñó como asesor científico comercial en una empresa líder en el desarrollo y comercialización de citómetros de flujo, experiencia que le permitió adquirir un conocimiento profundo de la instrumentación, sus fundamentos físicos y ópticos, así como sus aplicaciones en investigación biomédica y diagnóstico clínico.

Actualmente es académico del programa Investigadores por México de la Secretaría de Ciencia, Humanidades, Tecnología e Innovación ([SECIHTI](#)), comisionado al Hospital de Alta Especialidad de la Península de Yucatán ([HRAEPY](#)) del IMSS-BIENESTAR. Además, es profesor del capítulo de Citometría de Flujo de la Sociedad Mexicana de Inmunología ([SMI](#)), donde participa activamente en la formación de especialistas mediante la impartición de talleres y cursos sobre fundamentos, diseño experimental y análisis avanzado de datos en citometría de flujo.

Parte I

I. EL ENTORNO

1 R & LA IDE

R es un lenguaje de programación y un entorno de software libre (código abierto) especializado en computación estadística, análisis de datos y gráficos. En el campo de la bioinformática, R se ha convertido en uno de los estándares fundamentales de la industria y la investigación científica.

El lenguaje de programación R es ampliamente utilizado entre estadísticos y mineros de datos para desarrollar bibliotecas de análisis de datos y estadísticas, al mismo tiempo que es uno de los lenguajes más populares entre los científicos de datos gracias a su flexibilidad y capacidad de expansión, ya que R puede ampliarse a través de paquetes creados por el usuario.

- **Enfoque analítico:** Fue diseñado específicamente por y para estadísticos, investigadores y científicos de datos.
- **Ecosistema de paquetes:** Cuenta con miles de [librerías](#) adicionales que permiten desde análisis genómicos complejos hasta la manipulación de millones de eventos celulares.
- **Comunidad:** Posee una comunidad científica y académica global muy activa que constantemente desarrolla nuevas metodologías y herramientas de código abierto

Nota

En **citometría de flujo**, R se utiliza como un entorno integral para sustituir o complementar los programas comerciales tradicionales, permitiendo automatizar análisis, procesar decenas de archivos .fcs en lote de forma reproducible y aplicar algoritmos de alta dimensión.

1.1. ¿Por qué usar R en lugar de software manual?

- **Automatización y escalabilidad:** Un análisis manual en interfaces visuales requiere trazar compuertas (gates) muestra por muestra. En R, una rutina procesa cientos de archivos en minutos con los mismos parámetros exactos.
- **Control de sesgo:** Las compuertas algorítmicas y estadísticas reducen la variabilidad inter-operador típica del gating manual.

- **Manejo de citometría multiparamétrica:** En paneles modernos de más de 20 a 50 parámetros (como en citometría espectral o CyTOF/citometría de masas), el análisis bivariado clásico es insuficiente. R aporta algoritmos de reducción de dimensionalidad y agrupamiento no supervisado.

2 POSITRON

El análisis de datos masivos provenientes de la citometría de flujo requiere no solo de algoritmos robustos, sino de una infraestructura de software que optimice el flujo de trabajo del científico. Aunque históricamente RStudio ha sido el estándar de oro para la comunidad de R, el panorama tecnológico actual exige herramientas más versátiles, veloces y capaces de integrar flujos de trabajo políglotas. Aquí es donde surge Positron.

Positron es un entorno de desarrollo integrado (IDE) gratuito y de última generación diseñado específicamente para la ciencia de datos. Desarrollado por **Posit**, este entorno representa la evolución natural de las herramientas de programación científica, facilitando un trabajo fluido y nativo tanto en R como en Python.

2.1. Arquitectura moderna en ciencia de datos

A diferencia de otros editores genéricos, Positron no nace desde cero, sino que combina de manera fluida lo mejor de dos mundos. Por un lado, al haber sido construido como una rama de *Visual Studio Code*, hereda de inmediato la potencia de su arquitectura: una interfaz de codificación ultramoderna, un rendimiento de memoria excepcionalmente veloz y acceso a un ecosistema masivo de extensiones y personalización avanzada. Por el otro, el equipo de Posit ha inyectado en esta estructura toda la experiencia acumulada durante más de una década creando y manteniendo RStudio. El resultado no es un simple editor de texto general al que se le añaden complementos, sino un entorno diseñado desde su núcleo por y para científicos de datos.

Al trabajar en la automatización de los análisis citométricos, Positron ofrece funciones críticas orientadas a mejorar la reproducibilidad y la velocidad de ejecución:

- **Explorador de Datos Integrado:** Permite inspeccionar *data frames*, matrices y estructuras complejas de manera visual y de alto rendimiento, ideal para verificar las dimensiones de las matrices de expresión celular o metadatos de archivos FCS.
- **Gestión Inteligente de Intérpretes:** Permite cambiar entre diferentes versiones de R o entornos virtuales de Python con un solo clic, garantizando que los proyectos de Bioconductor utilicen siempre las dependencias correctas.
- **Asistencia de IA Nativa:** Ayuda a depurar *scripts*, optimizar *bucles* de análisis o autocompletar código de gráficos complejos rápidamente.

2.2. Anatomía del entorno de trabajo en Positron

La interfaz de Positron ha sido meticulosamente estructurada para maximizar la eficiencia en el análisis de datos. Si se viene de entornos tradicionales como RStudio o VS Code, se notará un diseño familiar pero profundamente optimizado para flujos de trabajo científicos.

Los componentes principales que gobiernan este IDE se dividen en cinco zonas (Figura 1) clave:

- **Barra de Actividad (*Activity Bar*)**: Ubicada habitualmente en el extremo lateral, funciona como el centro de control global del IDE. Proporciona acceso inmediato a módulos esenciales como el Explorador de archivos, el motor de Búsqueda indexada, el sistema de Control de Versiones (Git), la gestión de Extensiones y las configuraciones del sistema.
- **Barra Lateral Principal (*Primary Side Bar*)**: Este panel dinámico muta su contenido según el módulo activo en la Barra de Actividad. Por ejemplo, al activar la vista de gestión de archivos, se despliega aquí un árbol de directorios interactivo para navegar por las carpetas del proyecto.
- **Editor de Código (*Editor*)**: El núcleo operativo de la interfaz. Es el área de alta velocidad destinada a la escritura de scripts de R, archivos Quarto (.qmd) o código Python, equipado con autocompletado inteligente, resaltado de sintaxis y asistencia en tiempo real.
- **Panel Central Inferior (*Console & Terminal*)**: La zona de ejecución interactiva. Aloja las consolas nativas de programación (donde se interpretan y devuelven los comandos de R o Python de forma inmediata) y la Terminal del sistema operativo para tareas de administración del entorno.
- **Barra Lateral Secundaria (*Secondary Side Bar*)**: La innovación analítica de Positron. Este panel está dedicado exclusivamente a la inspección de la ciencia de datos en ejecución: aquí se auditan las variables cargadas en el entorno (*Environment*), se previsualizan los gráficos generados, se consulta la documentación técnica de las funciones y se interactúa con el Explorador de Datos integrado.




Figura 1. Entorno de trabajo Positron

3 ACTIVIDADES DE APRENDIZAJE

Hecho con por Jairo

4 PAQUETES

4.1. Paquetes de R

Un **paquete** de R es un conjunto estandarizado de funciones, código, datos y documentación que amplía las capacidades base del lenguaje. En el ámbito de la citometría de flujo, un paquete funciona como una caja de herramientas especializada que traduce algoritmos complejos y operaciones estadísticas en comandos sencillos, permitiendo procesar millones de eventos celulares sin tener que programar cada procedimiento desde cero.

4.2. Paquetes en citometría de flujo

La citometría de flujo genera archivos complejos (.fcs) con datos multidimensionales difíciles de manejar con software tradicional. Los paquetes especializados están diseñados para cubrir cada etapa del flujo de trabajo analítico:

- **Lectura e importación:** Permiten cargar archivos .fcs y estructurar los datos en matrices organizadas dentro de R.
- **Preprocesamiento:** Facilitan la compensación de fluorescencia (corrección de la superposición espectral entre fluoróforos) y las transformaciones matemáticas de los ejes.
- **Identificación celular (*gating*):** Ofrecen herramientas para delimitar poblaciones celulares de forma manual, reproducible o mediante algoritmos automatizados.
- **Visualización avanzada:** Generan gráficos de dispersión, mapas de calor y proyecciones de alta dimensión (como t-SNE o UMAP).

Ejemplos esenciales de paquetes citométricos

- **flowCore:** Es la columna vertebral del ecosistema; define las clases de datos básicas (como **flowFrame**) para manipular la información cruda.
- **flowViz:** Se centra en la representación gráfica, permitiendo crear histogramas y diagramas de contorno adaptados a la citometría.
- **openCyto:** Automatiza el proceso de gating para estandarizar la compuerta analítica en grandes estudios clínicos.

En resumen: Los paquetes actúan como el puente indispensable que transforma los datos crudos del citómetro en descubrimientos biológicos interpretables.

5 ACTIVIDADES DE APRENDIZAJE

Hecho con por Jairo

6 REPOSITARIOS

6.1. Repositorio de paquetes de R

Un **repositorio de paquetes** en R es una plataforma centralizada que almacena, valida y distribuye colecciones de código, funciones, datos y documentación. Funcionan de manera similar a una tienda de aplicaciones: permiten que cualquier usuario instale herramientas desarrolladas por la comunidad científica y las incorpore de forma inmediata a su sesión de trabajo.

Para el análisis de citometría de flujo, interactuaremos principalmente con dos ecosistemas complementarios: **CRAN** (para herramientas estadísticas y de visualización general) y **Bioconductor** (para el tratamiento especializado de datos biológicos).

6.1.1. CRAN

La Red Integral de Archivos de R (*Comprehensive R Archive Network*, CRAN) es el repositorio oficial y más extenso del lenguaje R (1). Mantenido por una red global de servidores coordinada por el *R Core Team*, CRAN no solo aloja el código fuente y los instaladores del sistema base de R, sino también miles de paquetes contribuidos por desarrolladores de todo el mundo.

Los paquetes publicados en CRAN deben superar rigurosas pruebas automáticas de estabilidad, portabilidad y documentación antes de ser aceptados (2). En nuestro flujo de trabajo, utilizaremos CRAN principalmente para instalar paquetes de manipulación tabular y visualización de datos, tales como el ecosistema **tidyvers**, **ggplot2** o utilidades de lectura de tablas.

6.1.2. Bioconductor

A diferencia de CRAN, cuyo alcance es de propósito general, **Bioconductor** es un repositorio fundado específicamente para la bioinformática y el análisis computacional de datos genómicos y biomédicos de alto rendimiento.

En citometría de flujo, Bioconductor constituye el estándar de referencia indispensable debido a dos pilares fundamentales:

- **Actualizaciones coordinadas y estabilidad:** Bioconductor publica dos versiones al año sincronizadas con las versiones de R. Este modelo evita conflictos de dependencias y asegura que los paquetes sean plenamente compatibles entre sí.
- **Estandarización de estructuras de datos:** Establece clases de objetos formales y compartidas (como `flowFrame` para una muestra individual o `flowSet` para una colección de muestras). Esto garantiza que distintas herramientas analíticas puedan leer, transformar e intercambiar información de archivos estándar `.fcs` sin errores de incompatibilidad.

Dentro de este ecosistema, existe una suite especializada de paquetes que cubre cada etapa del flujo analítico básico:

Tabla 6.1: El ecosistema clave en Bioconductor

Etapa	Paquetes de R	Función principal
Importación e infraestructura	<code>flowCore</code>	Lectura de archivos estándar <code>.fcs</code> , manipulación de metadatos, matrices de compensación y objetos <code>flowFrame</code> / <code>flowSet</code>
<i>Gating</i> reproducible	<code>flowWorkspace</code> , <code>openCyto</code>	Importación de espacios de trabajo y <i>gatings</i> automáticas basadas en densidad y modelos de mezclas gaussianas
Visualización estándar	<code>flowViz</code> , <code>ggcyto</code>	Extensión de <code>ggplot2</code> adaptada para citometría: histogramas, gráficos de densidad y visualización de compuertas 2D
Reducción de dimensionalidad	<code>Rtsne</code> , <code>uwot</code> (UMAP)	Proyección de poblaciones celulares complejas en espacios bidimensionales interactivos.
Clustering no supervisado	<code>FlowSOM</code> , <code>PhenoGraph</code>	Agrupamiento automatizado de subpoblaciones celulares utilizando mapas autoorganizados y grafos de vecindad.
Análisis diferencial	<code>diffcyt</code>	Detección estadística de cambios en la abundancia de poblaciones o en la expresión de marcadores funcionales entre condiciones experimentales.

7 ACTIVIDADES DE APRENDIZAJE

Hecho con por Jairo

Parte II

II. FORMATO DE TABLAS

8 ACTIVIDADES DE APRENDIZAJE

9

Hecho con por Jairo

10 CAPÍTULO 5

Hecho con por Jairo

Síntesis

In summary, this book has no content whatsoever.

Referencias

1. Mora-Cantalops M, Sánchez-Alonso S, García-Barriocanal E. A Complex Network Analysis of the Comprehensive R Archive Network (CRAN) Package Ecosystem. *Journal of Systems and Software*. diciembre de 2020;170:110744. doi:[10.1016/j.jss.2020.110744](https://doi.org/10.1016/j.jss.2020.110744)
2. Hornik K. The Comprehensive R Archive Network. *WIREs Computational Statistics*. julio de 2012;4(4):394-8. doi:[10.1002/wics.1212](https://doi.org/10.1002/wics.1212)