

DEL CITÓMETRO A LA CONSOLA

Fundamentos de R para el manejo de datos de citometría

Jairo Ricardo Villanueva-Toledo

2026-10-06

Tabla de contenidos

Portada	4
Licencia	5
CÓDIGO Y CONTENIDO PROPIO	5
Conjuntos de datos (<i>datasets</i>) de terceros	5
Prefacio	6
Introducción	7
El cambio de paradigma: Del software cerrado al código abierto	7
El entorno de trabajo: Positron	7
Estructura y alcance de este volumen	7
Acerca del Autor	9
 I I. FUNDAMENTOS	 11
1 R & LA IDE	12
1.1 ¿Por qué usar R en lugar de software manual?	12
2 POSITRON	13
3 ACTIVIDADES DE APRENDIZAJE	14
4 PAQUETES	15
4.1 Paquetes de R	15
4.2 Paquetes en citometría de flujo	15
5 ACTIVIDADES DE APRENDIZAJE	17
6 REPOSITORIOS	18
6.1 Repositorio de paquetes de R	18
6.1.1 CRAN	18
6.1.2 Bioconductor	18
7 ACTIVIDADES DE APRENDIZAJE	20

II	II. XXX	21
8	ACTIVIDADES DE APRENDIZAJE	22
10	CAPÍTULO 5	24
	Síntesis	25
	Referencias	26

Portada

Licencia

CÓDIGO Y CONTENIDO PROPIO

El código fuente de los ejemplos y análisis presentados en este libro se distribuye bajo la licencia MIT (libre para su uso y modificación en tus propios análisis).

El contenido textual, explicaciones e imágenes de este libro web están sujetos a la licencia **Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional (CC BY-NC-ND 4.0)**.

La versión oficial consolidada, revisada y optimizada para formatos impresos y lectores electrónicos (eBook) estará disponible próximamente a través de los principales canales de distribución editorial.

i NOTA DEL AUTOR

Nos reservamos el derecho de publicar versiones futuras con contenido adicional, correcciones y mejoras en la arquitectura del código. Para consultas sobre derechos de uso comercial, reproducción o distribución masiva, por favor contacta al autor a través de su perfil académico o redes sociales profesionales.

Conjuntos de datos (*datasets*) de terceros

Para el desarrollo de los ejemplos y casos prácticos de análisis presentados en esta obra, se ha utilizado el dataset original “**AutoSpectral: Full Workflow Example**” (V1), creado por **Oliver Burton, James Dooley y Adrian Liston (2025)** y alojado en *Mendeley Data* (doi: [10.17632/ch5dnspd79.1](https://doi.org/10.17632/ch5dnspd79.1)).

Este conjunto de datos está disponible bajo la licencia **Creative Commons Attribution 4.0 International (CC BY 4.0)**. Los datos originales fueron procesados y modificados por el autor de este libro con fines estrictamente didácticos (incluyendo tareas de limpieza, filtrado y reestructuración para adaptar el flujo de trabajo a los ejemplos del texto). Puede consultar los términos completos de la licencia de este dataset en: <https://creativecommons.org/licenses/by/4.0/>.

Prefacio

Durante décadas, la citometría de flujo se ha consolidado como una de las herramientas más determinantes de la investigación biomédica, permitiendo caracterizar la heterogeneidad celular con resolución de célula única. Sin embargo, la rutina diaria frente al citómetro ha estado tradicionalmente ligada a un flujo de trabajo manual: adquirir las muestras, realizar compensaciones visuales, delimitar poblaciones mediante compuertas en gráficos bidimensionales (*point-and-click*) y copiar manualmente tablas de resultados a hojas de cálculo.

Este enfoque, aunque familiar y accesible en los inicios de cualquier investigador, enfrenta barreras evidentes en el laboratorio contemporáneo. Conforme los experimentos aumentan en número de marcadores, muestras y réplicas, el análisis tradicional tropieza con tres obstáculos fundamentales:

- **Subjetividad metodológica:** El trazado manual de compuertas introduce variabilidad atribuible al operador, lo que dificulta la reproducibilidad exacta de los resultados a lo largo del tiempo o entre distintos miembros de un equipo.
- **Falta de trazabilidad:** Las interfaces comerciales no siempre generan un registro auditable e inmutable de las operaciones realizadas, complicando la reconstrucción minuciosa del tratamiento de los datos.
- **Ineficiencia en el escalamiento:** Repetir secuencias idénticas de clics para decenas o cientos de archivos consume tiempo valioso de mesada y multiplica las probabilidades de cometer errores de transcripción.

Ante este panorama, la programación estadística mediante R y su repositorio especializado Bioconductor se ha posicionado como el estándar metodológico para procesar y reportar datos citométricos. No obstante, para quien proviene de la formación experimental, la transición a la programación suele percibirse como un abismo lleno de jerga computacional innecesaria.

Del citómetro a la consola: Fundamentos de R para el manejo de datos de citometría nace para derribar esa barrera. Este texto no pretende formar desarrolladores de software ni teóricos de la bioinformática; su único propósito es servir de puente entre el trabajo en la mesa de trabajo y la línea de comandos, dotando al investigador de autonomía analítica, orden y reproducibilidad desde su primera sesión de trabajo.

Introducción

El cambio de paradigma: Del software cerrado al código abierto

Aprender R en citometría no implica abandonar el criterio biológico; al contrario, significa dotarlo de rigor metodológico. La adopción de código convierte cada análisis en una bitácora científica explícita, auditable y automatizable, donde cada transformación y cálculo queda registrado de principio a fin.

El ecosistema de R permite conectar directamente los archivos crudos de adquisición con tablas procesadas y figuras listas para publicación, garantizando que cualquier experimento pueda reanalizarse exactamente bajo las mismas condiciones.

El entorno de trabajo: Positron

La adopción de R estuvo históricamente centrada en RStudio. No obstante, las necesidades actuales de la ciencia de datos han impulsado entornos más ágiles y modernos. Este libro adopta Positron como el entorno de desarrollo integrado (IDE) de referencia.

Diseñado por Posit sobre la arquitectura Code-OSS, Positron combina la potencia de un editor ligero con herramientas esenciales para el análisis biológico: consolas interactivas, visores directos de gráficos y un panel de inspección de variables optimizado. Para quien escribe código por primera vez, Positron reduce sustancialmente la curva de entrada, permitiendo explorar estructuras tabulares y matrices celulares de forma visual e intuitiva.

Estructura y alcance de este volumen

Este volumen introductorio se enfoca en los pilares mecánicos y conceptuales necesarios para importar, examinar y transformar datos citométricos sin recurrir a paquetes herméticos de caja negra. El eje central de la obra radica en desmitificar el archivo `.fcs` y dominar la estructura universal de datos en R: el `data.frame` y sus variantes modernas.

El contenido se articula en cuatro bloques progresivos:

- **Entorno y primeros pasos en Positron:** Instalación del software, configuración del intérprete de R, navegación por la consola y uso efectivo del panel Variables/Environment para inspeccionar lo que cargamos en memoria.
- **De la matriz FCS al mundo tabular (data.frame y variantes):** Comprensión de cómo paqueterías como flowCore leen la estructura de un archivo .fcs (metadatos, palabras clave e intensidades) y cómo desmitificar el objeto extrayendo la matriz de eventos celulares para transformarla en estructuras familiares: el data.frame base y sus variantes modernas (tibble y data.table).
- **Manipulación e inspección de datos celulares:** Uso de sintaxis básica y herramientas del ecosistema tidyverse para filtrar filas (eventos celulares), seleccionar columnas (marcadores/fluorocromos), renombrar canales y generar estadísticas descriptivas (medianas de fluorescencia, porcentajes y conteos).
- **Visualización gráfica inicial:** Creación de gráficos reproducibles de calidad editorial (histogramas univariados, diagramas de dispersión y densidades) mediante ggplot2, controlando escalas, títulos y estéticas para reportes y presentaciones.

Al concluir este volumen, el lector habrá sustituido la dependencia de herramientas cerradas por un flujo de trabajo transparente y reproducible, estableciendo las bases requeridas para abordar análisis avanzados en volúmenes posteriores.

Acerca del Autor



El autor es Médico Cirujano por la Universidad Autónoma de Yucatán ([UADY](#)). Posteriormente, realizó estudios de posgrado en el Centro de Investigación y de Estudios Avanzados del Instituto Politécnico Nacional ([CINVESTAV-IPN](#)), sede Zacatenco, en la Ciudad de México, donde obtuvo los grados de Maestría y Doctorado en Ciencias con especialidad en Genética y Biología Molecular.

Durante su formación de posgrado incursionó de manera paralela en bioinformática y citometría de flujo, áreas que marcarían de forma decisiva su trayectoria profesional. En bioinformática trabajó en análisis de secuencias génicas utilizando entornos UNIX y el lenguaje Perl,

incluyendo búsquedas con BLAST y diseño de *primers*. De manera simultánea, desarrolló experiencia en citometría de flujo aplicada al análisis del ciclo celular, integrando herramientas computacionales con aproximaciones experimentales para el estudio de procesos biológicos complejos. Actualmente complementa esta línea de trabajo mediante el uso de los lenguajes de programación R y Python para el análisis, procesamiento y visualización de datos biológicos.

Tras concluir el doctorado, se desempeñó como asesor científico comercial en una empresa líder en el desarrollo y comercialización de citómetros de flujo, experiencia que le permitió adquirir un conocimiento profundo de la instrumentación, sus fundamentos físicos y ópticos, así como sus aplicaciones en investigación biomédica y diagnóstico clínico.

Actualmente es académico del programa Investigadores por México de la Secretaría de Ciencia, Humanidades, Tecnología e Innovación ([SECIHTI](#)), comisionado al Hospital de Alta Especialidad de la Península de Yucatán ([HRAEPY](#)) del IMSS-BIENESTAR. Además, es profesor del capítulo de Citometría de Flujo de la Sociedad Mexicana de Inmunología ([SMI](#)), donde participa activamente en la formación de especialistas mediante la impartición de talleres y cursos sobre fundamentos, diseño experimental y análisis avanzado de datos en citometría de flujo.

Parte I

I. FUNDAMENTOS

1 R & LA IDE

R es un lenguaje de programación y un entorno de software libre (código abierto) especializado en computación estadística, análisis de datos y gráficos. En el campo de la bioinformática, R se ha convertido en uno de los estándares fundamentales de la industria y la investigación científica.

- **Enfoque analítico:** Fue diseñado específicamente por y para estadísticos, investigadores y científicos de datos.
- **Ecosistema de paquetes:** Cuenta con miles de [librerías](#) adicionales que permiten desde análisis genómicos complejos hasta la manipulación de millones de eventos celulares.
- **Comunidad:** Posee una comunidad científica y académica global muy activa que constantemente desarrolla nuevas metodologías y herramientas de código abierto

Nota

En **citometría de flujo**, R se utiliza como un entorno integral para sustituir o complementar los programas comerciales tradicionales, permitiendo automatizar análisis, procesar decenas de archivos .fcs en lote de forma reproducible y aplicar algoritmos de alta dimensión.

1.1. ¿Por qué usar R en lugar de software manual?

- **Automatización y escalabilidad:** Un análisis manual en interfaces visuales requiere trazar compuertas (gates) muestra por muestra. En R, una rutina procesa cientos de archivos en minutos con los mismos parámetros exactos.
- **Control de sesgo:** Las compuertas algorítmicas y estadísticas reducen la variabilidad inter-operador típica del gating manual.
- **Manejo de citometría multiparamétrica:** En paneles modernos de más de 20 a 50 parámetros (como en citometría espectral o CyTOF/citometría de masas), el análisis bivariado clásico es insuficiente. R aporta algoritmos de reducción de dimensionalidad y agrupamiento no supervisado.

2 POSITRON

[Positron](#) es el entorno de desarrollo integrado (IDE) de última generación creado por Posit (la empresa detrás de RStudio). Está construido sobre el núcleo de código abierto de Code - OSS (la misma base técnica de Visual Studio Code), pero diseñado específicamente como un espacio de trabajo para la ciencia de datos en R y Python.

A diferencia de VS Code estándar —que requiere configurar múltiples extensiones— o del RStudio clásico —que fue pensado originalmente casi en exclusiva para R—, Positron viene preconfigurado con una arquitectura moderna que potencia enormemente el análisis bioinformático y la citometría de flujo.

- **ADN moderno y abierto:** Está construido sobre estándares abiertos (utilizando como base Code OSS, la misma plataforma tecnológica de Visual Studio Code), lo que permite aprovechar extensiones y una interfaz altamente personalizable.
- **Enfoque multi-lenguaje (Políglota):** A diferencia de RStudio (enfocado principalmente en R), Positron soporta de forma nativa y simultánea tanto R como Python, permitiendo trabajar con ambos lenguajes en un mismo proyecto sin fricciones.
- **Herramientas interactivas integradas:** Combina la comodidad de una interfaz orientada a datos (como un visor avanzado de dataframes, un panel dedicado a gráficos interactivos y un inspector de variables muy potente) con la flexibilidad de un editor de código moderno.

3 ACTIVIDADES DE APRENDIZAJE

Hecho con por Jairo

4 PAQUETES

4.1. Paquetes de R

Un **paquete** de R es un conjunto estandarizado de funciones, código, datos y documentación que amplía las capacidades base del lenguaje. En el ámbito de la citometría de flujo, un paquete funciona como una caja de herramientas especializada que traduce algoritmos complejos y operaciones estadísticas en comandos sencillos, permitiendo procesar millones de eventos celulares sin tener que programar cada procedimiento desde cero.

4.2. Paquetes en citometría de flujo

La citometría de flujo genera archivos complejos (.fcs) con datos multidimensionales difíciles de manejar con software tradicional. Los paquetes especializados están diseñados para cubrir cada etapa del flujo de trabajo analítico:

- **Lectura e importación:** Permiten cargar archivos .fcs y estructurar los datos en matrices organizadas dentro de R.
- **Preprocesamiento:** Facilitan la compensación de fluorescencia (corrección de la superposición espectral entre fluoróforos) y las transformaciones matemáticas de los ejes.
- **Identificación celular (*gating*):** Ofrecen herramientas para delimitar poblaciones celulares de forma manual, reproducible o mediante algoritmos automatizados.
- **Visualización avanzada:** Generan gráficos de dispersión, mapas de calor y proyecciones de alta dimensión (como t-SNE o UMAP).

Ejemplos esenciales de paquetes citométricos

- **flowCore:** Es la columna vertebral del ecosistema; define las clases de datos básicas (como **flowFrame**) para manipular la información cruda.
- **flowViz:** Se centra en la representación gráfica, permitiendo crear histogramas y diagramas de contorno adaptados a la citometría.
- **openCyto:** Automatiza el proceso de gating para estandarizar la compuerta analítica en grandes estudios clínicos.

En resumen: Los paquetes actúan como el puente indispensable que transforma los datos crudos del citómetro en descubrimientos biológicos interpretables.

5 ACTIVIDADES DE APRENDIZAJE

Hecho con por Jairo

6 REPOSITARIOS

6.1. Repositorio de paquetes de R

Un **repositorio de paquetes** de R es una plataforma centralizada que almacena, organiza y distribuye colecciones de código, funciones, datos y documentación listos para ser instalados y utilizados en el entorno R.

6.1.1. CRAN

Mientras que el repositorio genérico más conocido es [CRAN](#) (*Comprehensive R Archive Network*), la comunidad científica utiliza repositorios especializados que agrupan herramientas para disciplinas específicas, como la bioinformática.

6.1.2. Bioconductor

En el análisis de datos de citometría de flujo, el repositorio de referencia indiscutible es [Bioconductor](#). A diferencia de los repositorios generales, Bioconductor está optimizado para la investigación biomédica y ofrece ventajas esenciales:

- **Actualizaciones coordinadas:** Los paquetes se lanzan y actualizan dos veces al año, garantizando la compatibilidad entre versiones.
- **Estandarización:** Define clases de datos comunes (como `flowFrame` y `flowSet`) para que diferentes herramientas interactúen sin fricciones al leer archivos estándar de citometría (`.fcs`).

R cuenta con una suite especializada de paquetes para cada etapa del flujo de trabajo:

Tabla 6.1: El ecosistema clave en Bioconductor

Etapa	Paquetes de R	Función principal
Importación e infraestructura	flowCore	Lectura de archivos estándar .fcs, manipulación de metadatos, matrices de compensación y objetos flowFrame / flowSet
<i>Gating</i> reproducible	flowWorkspace , openCyto	Importación de espacios de trabajo y <i>gatings</i> automáticas basadas en densidad y modelos de mezclas gaussianas
Visualización estándar	flowViz , ggcyto	Extensión de ggplot2 adaptada para citometría: histogramas, gráficos de densidad y visualización de compuertas 2D
Reducción de dimensionalidad	Rtsne , uwot (UMAP)	Proyección de poblaciones celulares complejas en espacios bidimensionales interactivos.
Clustering no supervisado	FlowSOM , PhenoGraph	Agrupamiento automatizado de subpoblaciones celulares utilizando mapas autoorganizados y grafos de vecindad.
Análisis diferencial	diffcyt	Detección estadística de cambios en la abundancia de poblaciones o en la expresión de marcadores funcionales entre condiciones experimentales.

7 ACTIVIDADES DE APRENDIZAJE

Hecho con por Jairo

Parte II

II. XXX

8 ACTIVIDADES DE APRENDIZAJE

9

Hecho con por Jairo

10 CAPÍTULO 5

Hecho con por Jairo

Síntesis

In summary, this book has no content whatsoever.

Referencias